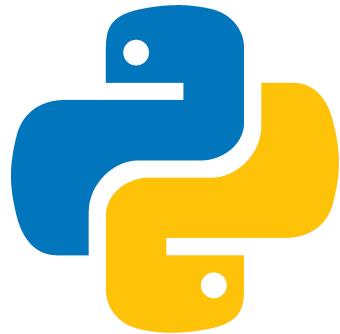


# Outils génériques de visualisation de données pour Python

Par Vincent Roger

23/11/2023





# À propos de moi

PhD en informatique.

Data scientist de Kiviak instrument et  
spécialiste de l'apprentissage automatique.

**LinkedIn**

<https://www.linkedin.com/in/vroger11/>

**Site web**

<https://website.vincent-roger.fr/>

# Pourquoi la visualisation de données avec Python ?

- L'extraction et la préparation des données sont simplifiées par des outils tels que Pandas, Dask et d'autres.
- Il s'agit d'un langage incontournable pour les scientifiques des données, l'apprentissage automatique et les personnes travaillant sur les MLOPS.
- Alors pourquoi apprendre un nouveau langage juste pour la visualisation de données ?

# Quels types d'outils

## Spécifiques (pour graphes)

- NetworkX
- Graph-tool
- PyGraphviz → Graphviz
- Pyvis

## Générique

Objectif de cette présentation !



# Plan

- Non orienté web
- Orienté web

# Données que nous allons utiliser

```
import pandas as pd  
  
df_iris = pd.read_csv('https://raw.githubusercontent.com/mwaskom/seaborn-data/master/iris.csv')  
  
df_iris
```

```
   sepal_length  sepal_width  petal_length  petal_width  species  
0          5.1         3.5         1.4         0.2    setosa  
1          4.9         3.0         1.4         0.2    setosa  
2          4.7         3.2         1.3         0.2    setosa  
3          4.6         3.1         1.5         0.2    setosa  
4          5.0         3.6         1.4         0.2    setosa  
..         ...         ...         ...         ...      ...  
145         6.7         3.0         5.2         2.3  virginica  
146         6.3         2.5         5.0         1.9  virginica  
147         6.5         3.0         5.2         2.0  virginica  
148         6.2         3.4         5.4         2.3  virginica  
149         5.9         3.0         5.1         1.8  virginica
```

[150 rows x 5 columns]

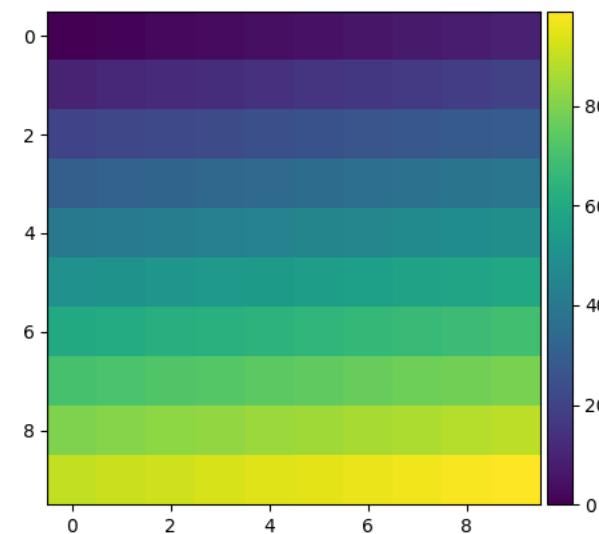
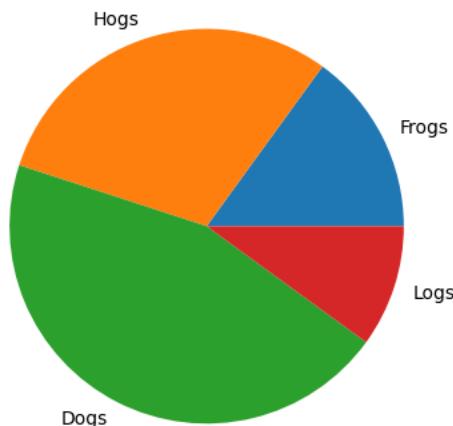
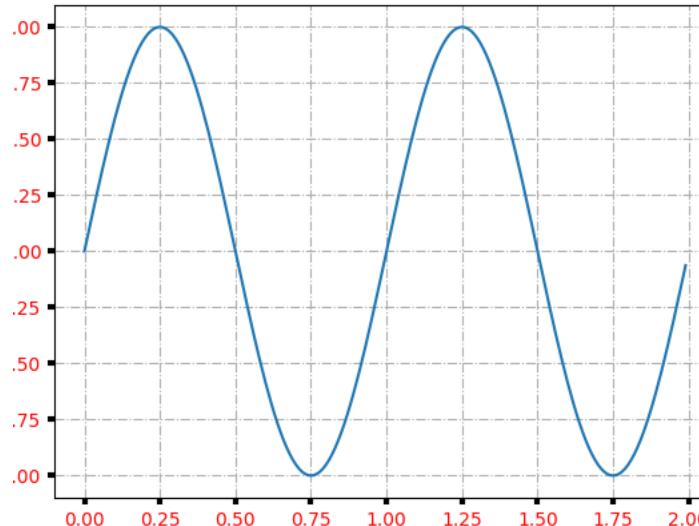


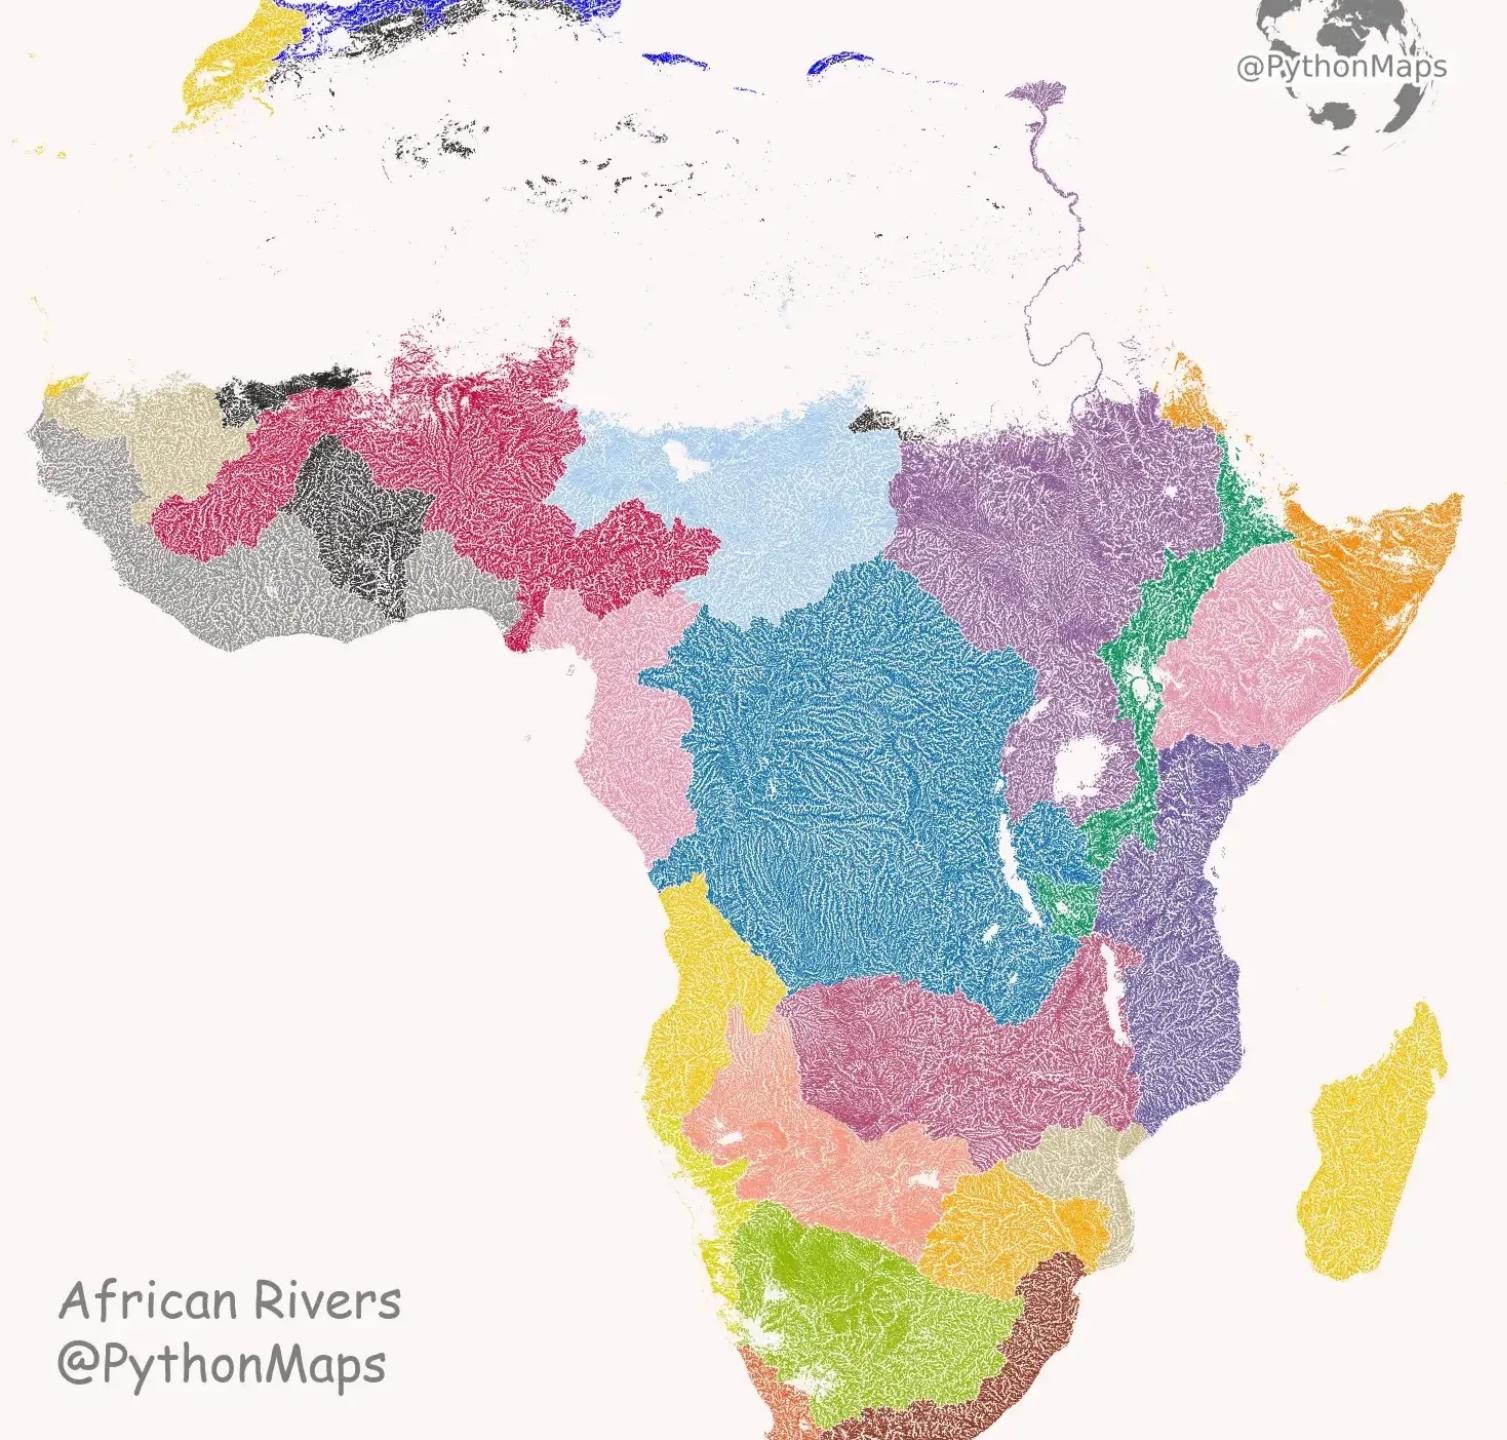


# Non orienté web

# Matplotlib

- Basé sur Qt.
- Bibliothèque standard.
- Par défaut pour de nombreux outils comme Pandas.





African Rivers  
@PythonMaps

## Matplotlib

- Puissant si maîtrisé !

## Matplotlib - diagramme de dispersion des sépales de l'iris

```
import matplotlib.pyplot as plt

# Create a scatter plot with legends based on species
plt.figure(figsize=(8, 6))

# Iterate over each species and plot scatter points
for species in df_iris["species"].unique():
    species_data = df_iris[df_iris['species'] == species]
    plt.scatter(species_data['sepal_length'], species_data['sepal_width'], label=species)

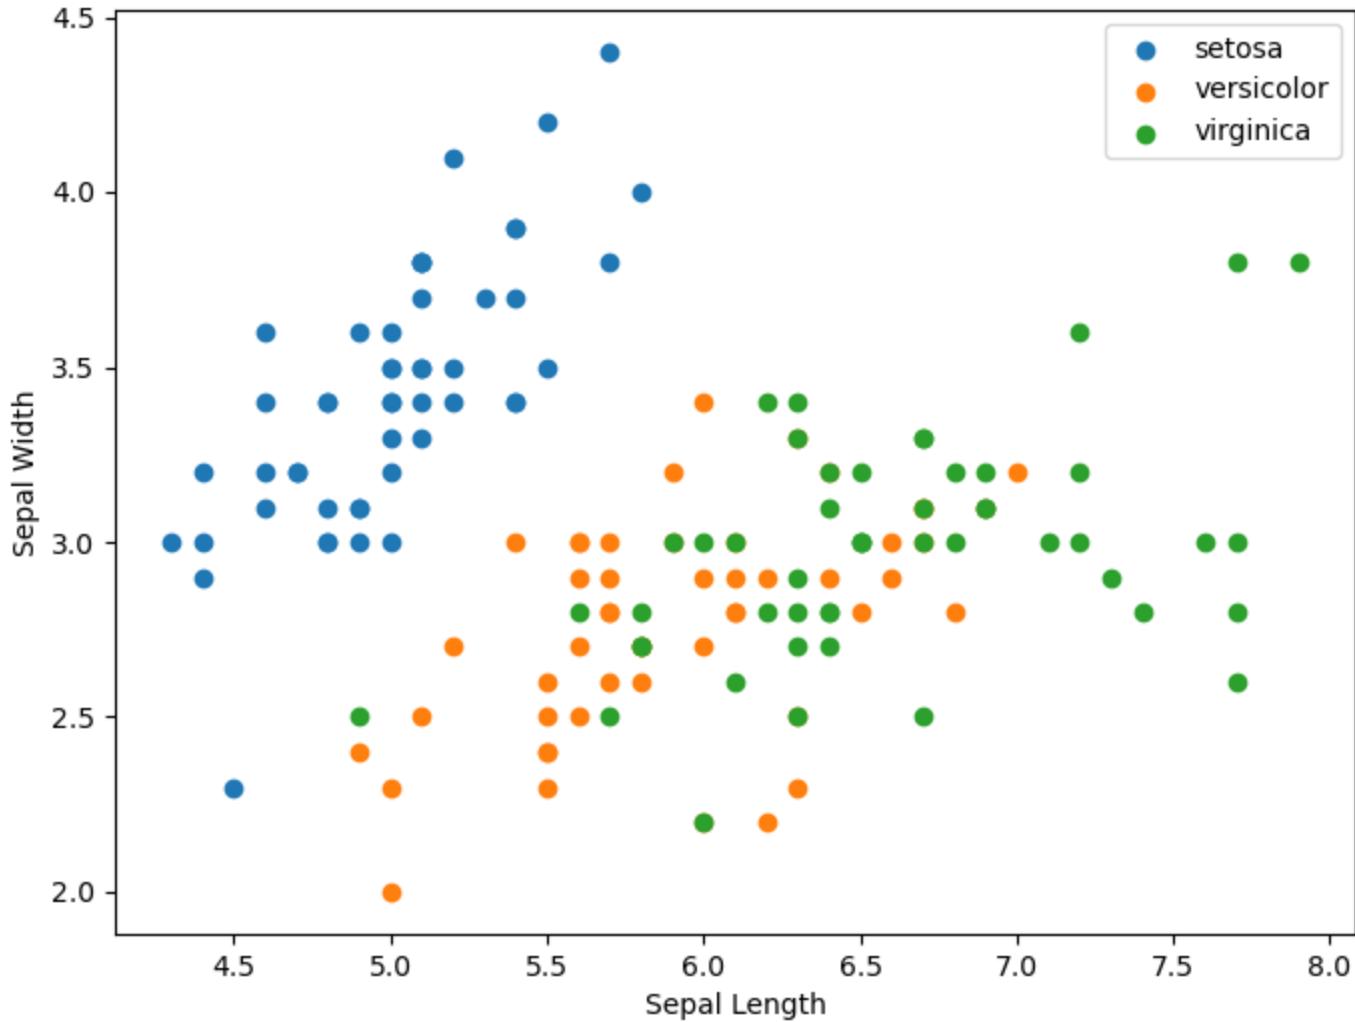
# Add labels and title
plt.xlabel('Sepal Length')
plt.ylabel('Sepal Width')
plt.title('Scatter Plot of Iris Dataset')

# Add legend
plt.legend()

# Show the plot
plt.show()
```



Scatter Plot of Iris Dataset



# Matplotlib

## Avantages :

- La librairie la plus utilisée.
- Travailler localement.
- Grande communauté.

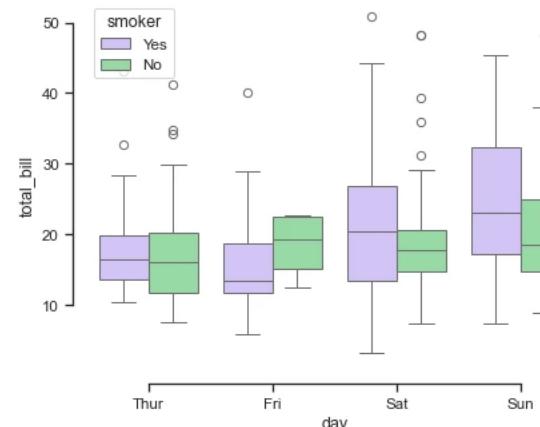
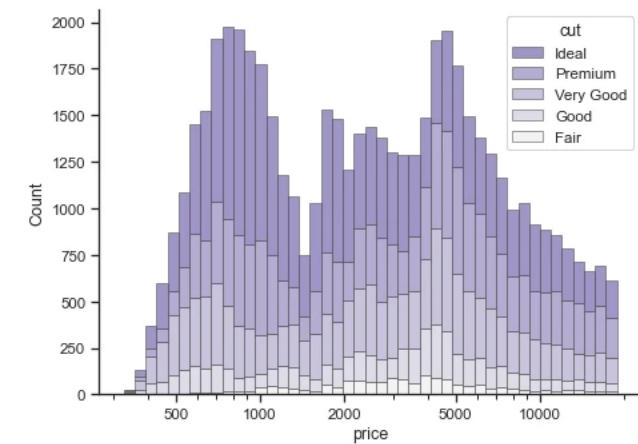
## Inconvénients :

- Verbeux.
- N'est pas bien adapté aux tracés dynamiques (en particulier avec de nombreux points de données).
- Il peut être difficile de réaliser certains tracés spécifiques.



## Seaborn

- Basé sur Matplotlib.
- Conçu pour les graphiques statistiques.



## Seaborn - diagramme de dispersion des sépales de l'iris

```
import matplotlib.pyplot as plt
import seaborn as sns

# Create a scatter plot
sns.scatterplot(data=df_iris, x="sepal_length", y="sepal_width", hue="species")

# Add labels and title
plt.xlabel('Sepal length')
plt.ylabel('Sepal width')
plt.title('Scatter Plot of Sepal')

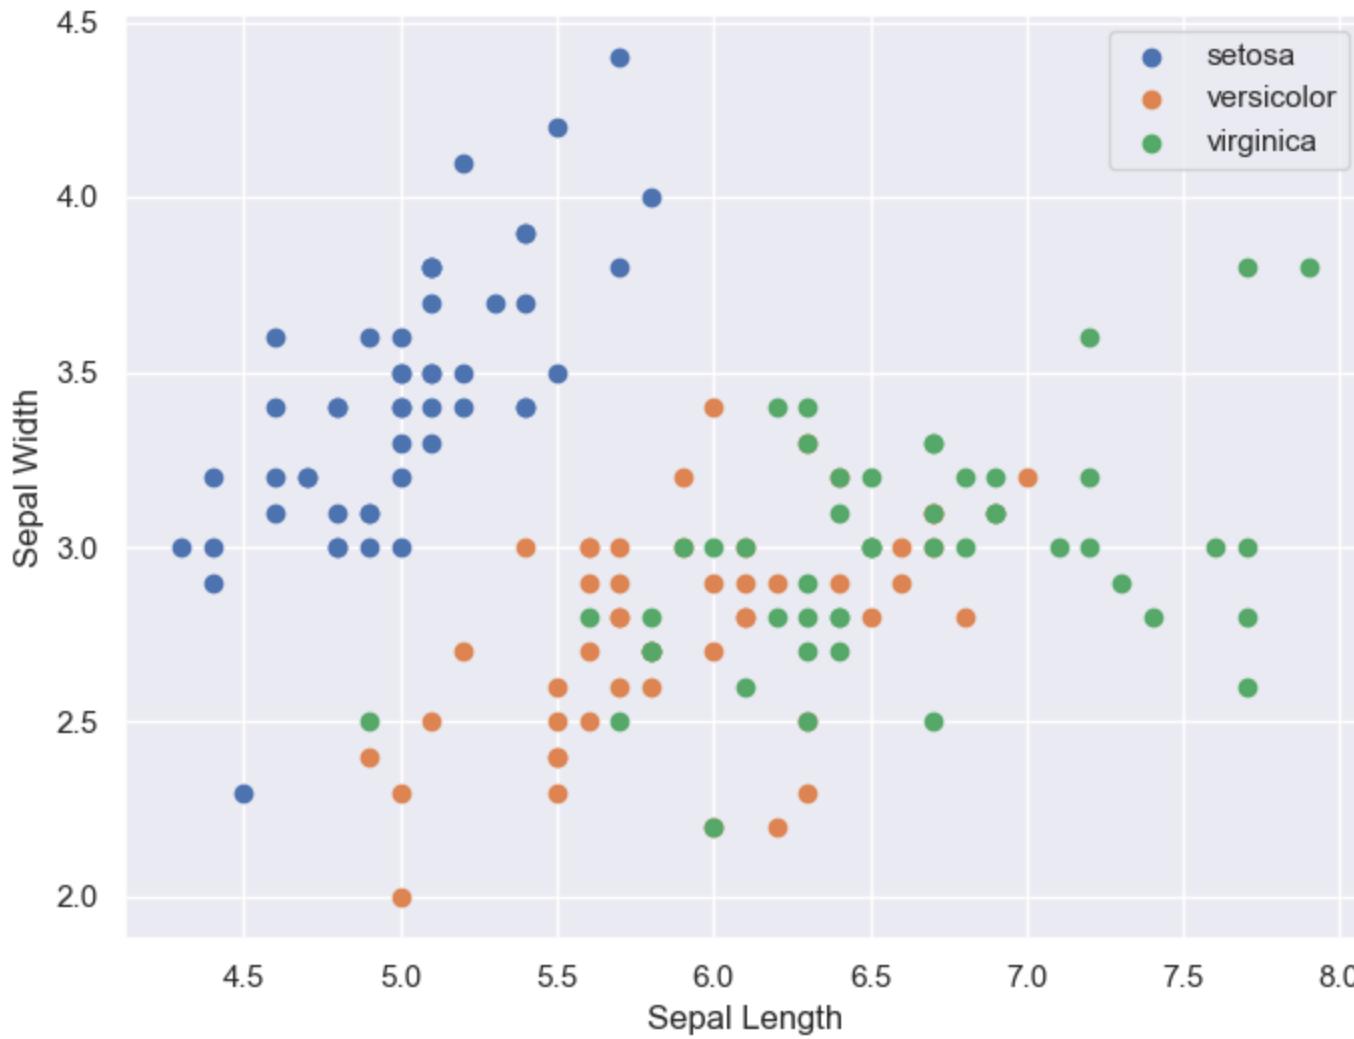
# Display the plot
plt.show()
```

X ^ v

Figure 1



Scatter Plot of Iris Dataset

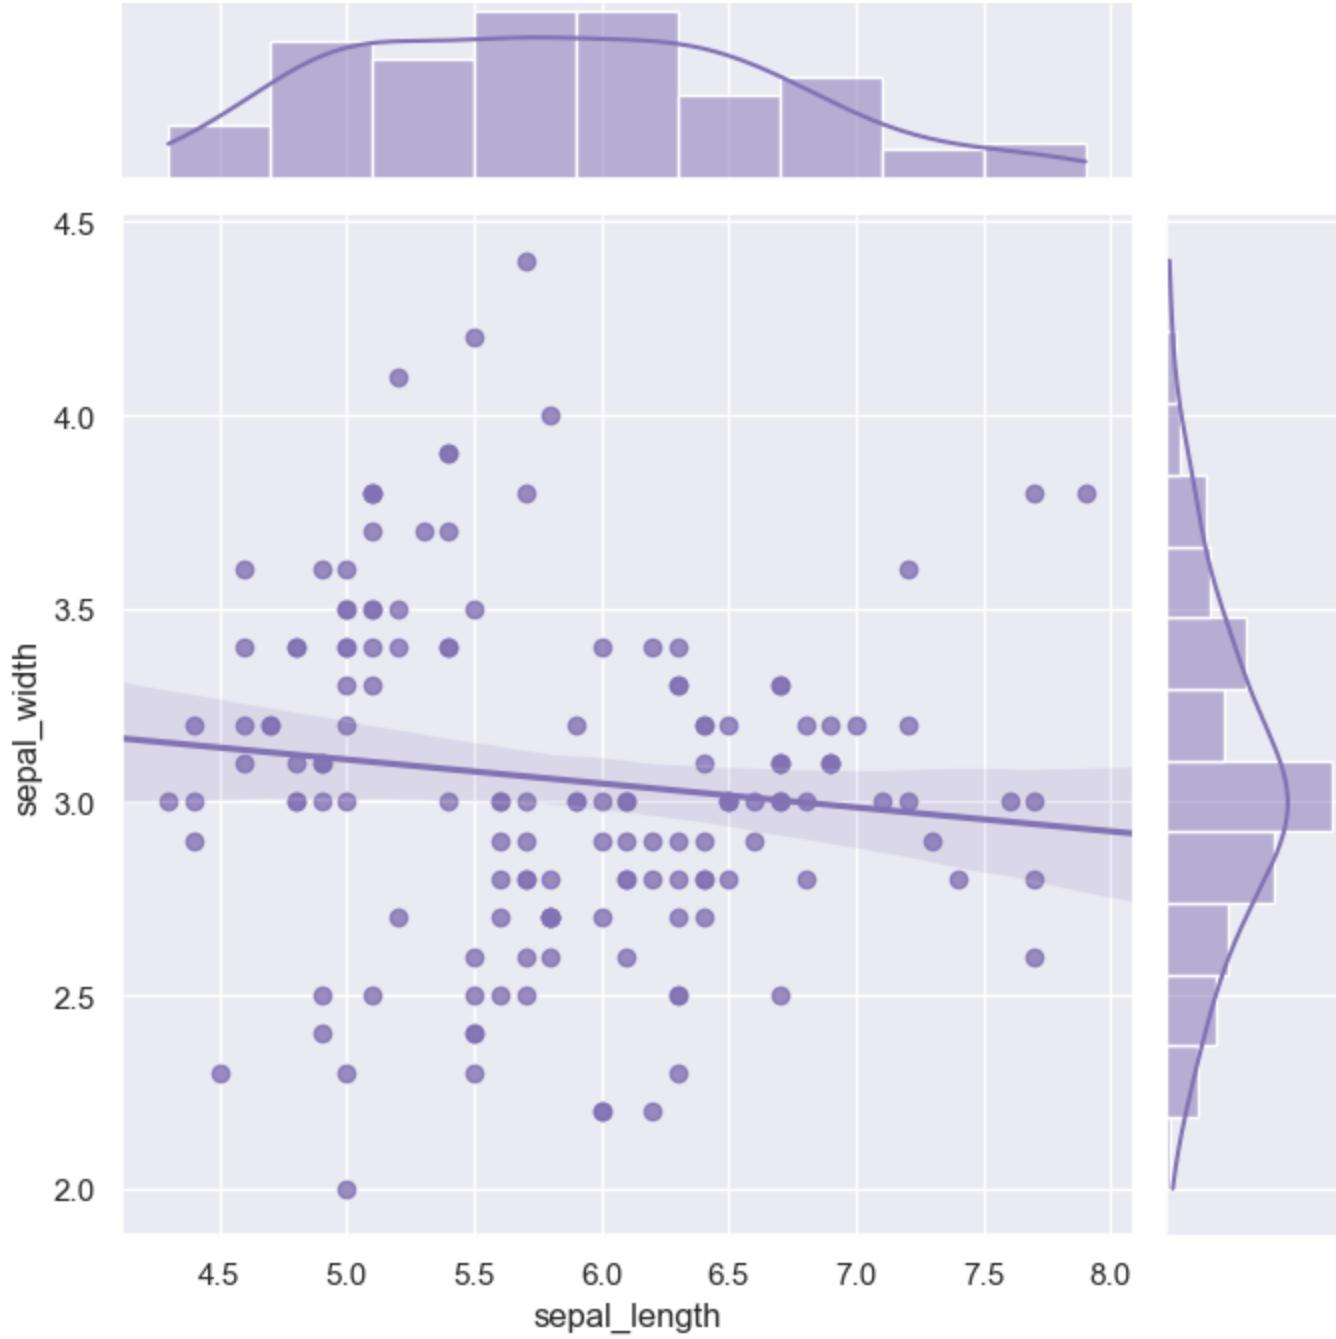


## Seaborn - faire rapidement des statistiques

```
import matplotlib.pyplot as plt
import seaborn as sns

# Compute jointplot
sns.set_theme(style="darkgrid")
g = sns.jointplot(data=df_iris, x="sepal_length", y="sepal_width",
                   kind="reg", truncate=False,
                   color="m", height=7)

# Display the plot
plt.show()
```



# Seaborn

## Avantages :

- Fournit des thèmes.
- Fournit des fonctions de haut niveau pour l'analyse statistique afin de faciliter certains tracés.

## Inconvénients :

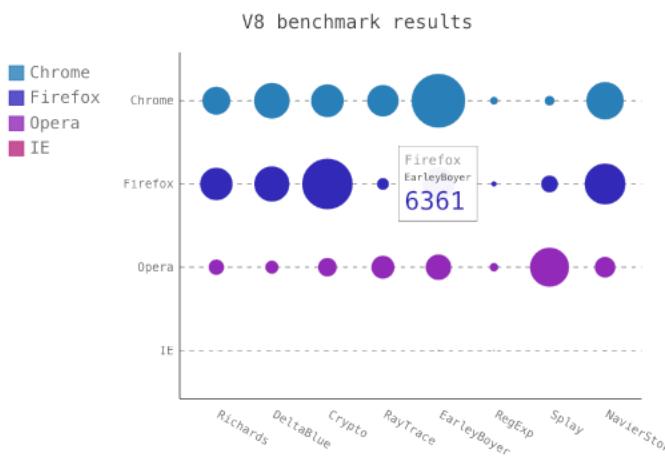
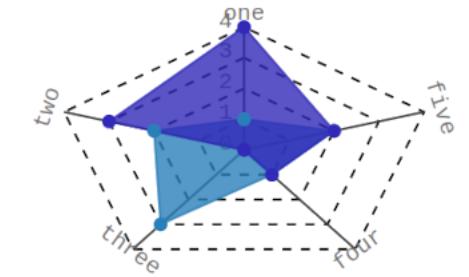
- Toujours un peu verbeux lors de la modification de certains tracés.
- N'est pas conçu pour les tracés dynamiques.
- Ne permet pas de générer tous les types de tracés.



## Pygal

- Produire des SVG dynamiques.
- Écrit en Python.

Radar Chart with Fill

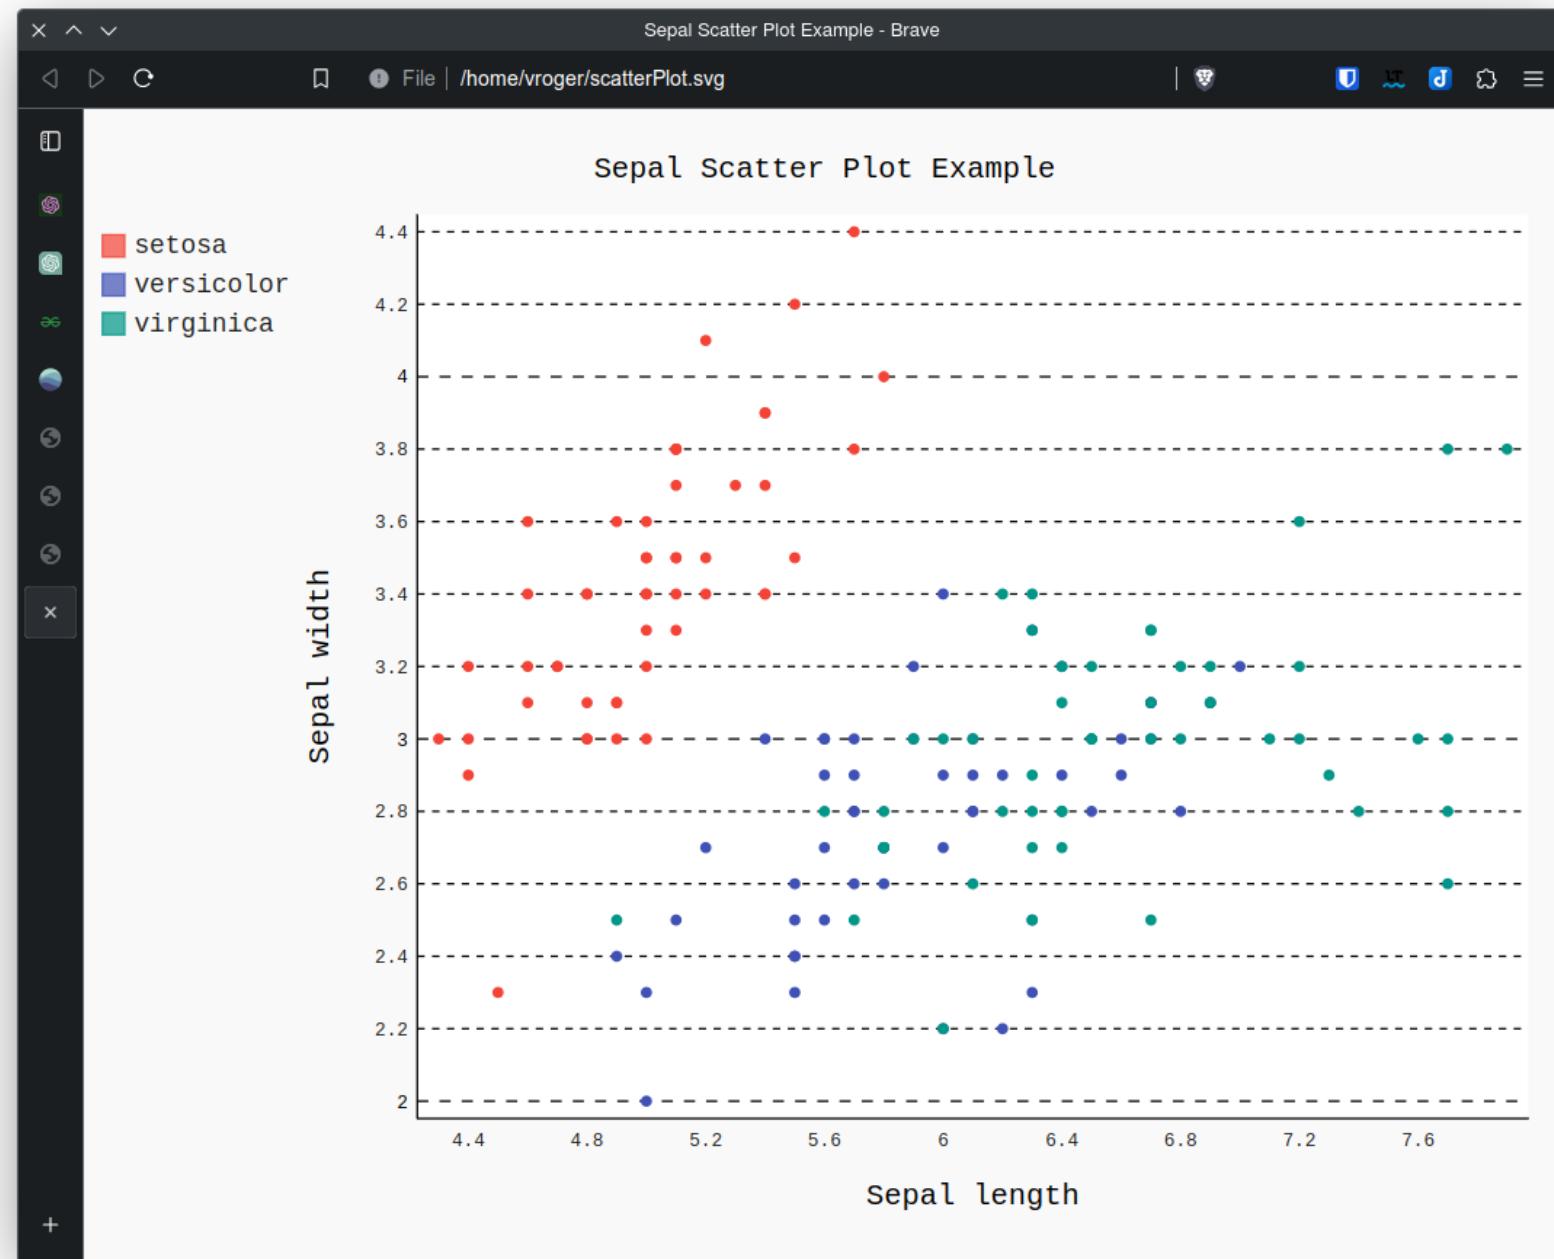


## Pygal - diagramme de dispersion des sépales de l'iris

```
import pygal

scatter_chart = pygal.XY(stroke=False)
for specie in df_iris["species"].unique():
    df_s = df_iris[df_iris["species"] == specie]
    scatter_chart.add(f'{specie}', list(zip(df_s["sepal_length"], df_s["sepal_width"])))

scatter_chart.title = 'Sepal Scatter Plot Example'
scatter_chart.x_title = 'Sepal length'
scatter_chart.y_title = 'Sepal width'
scatter_chart.render_to_file('scatterPlot.svg')
```



# Pygal

## Avantages

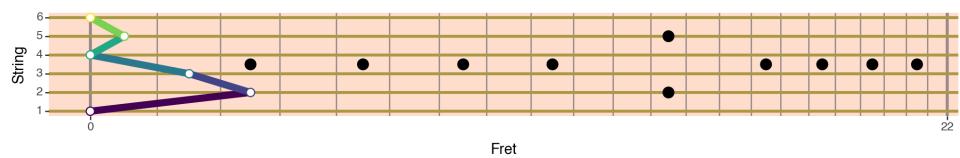
- Même si le résultat est un fichier SVG, il est interactif par défaut !
- Grande variété de graphiques.

## Inconvénients

- SVG compatible avec les navigateurs web, mais pas avec des logiciels comme Inkscape ou notebook (même avec rendu HTML).
- Les graphiques ne sont pas clairs avec les valeurs par défaut (en particulier la grille).

# Plotnine

- Implémentation de la grammaire de ggplot2 en Python.



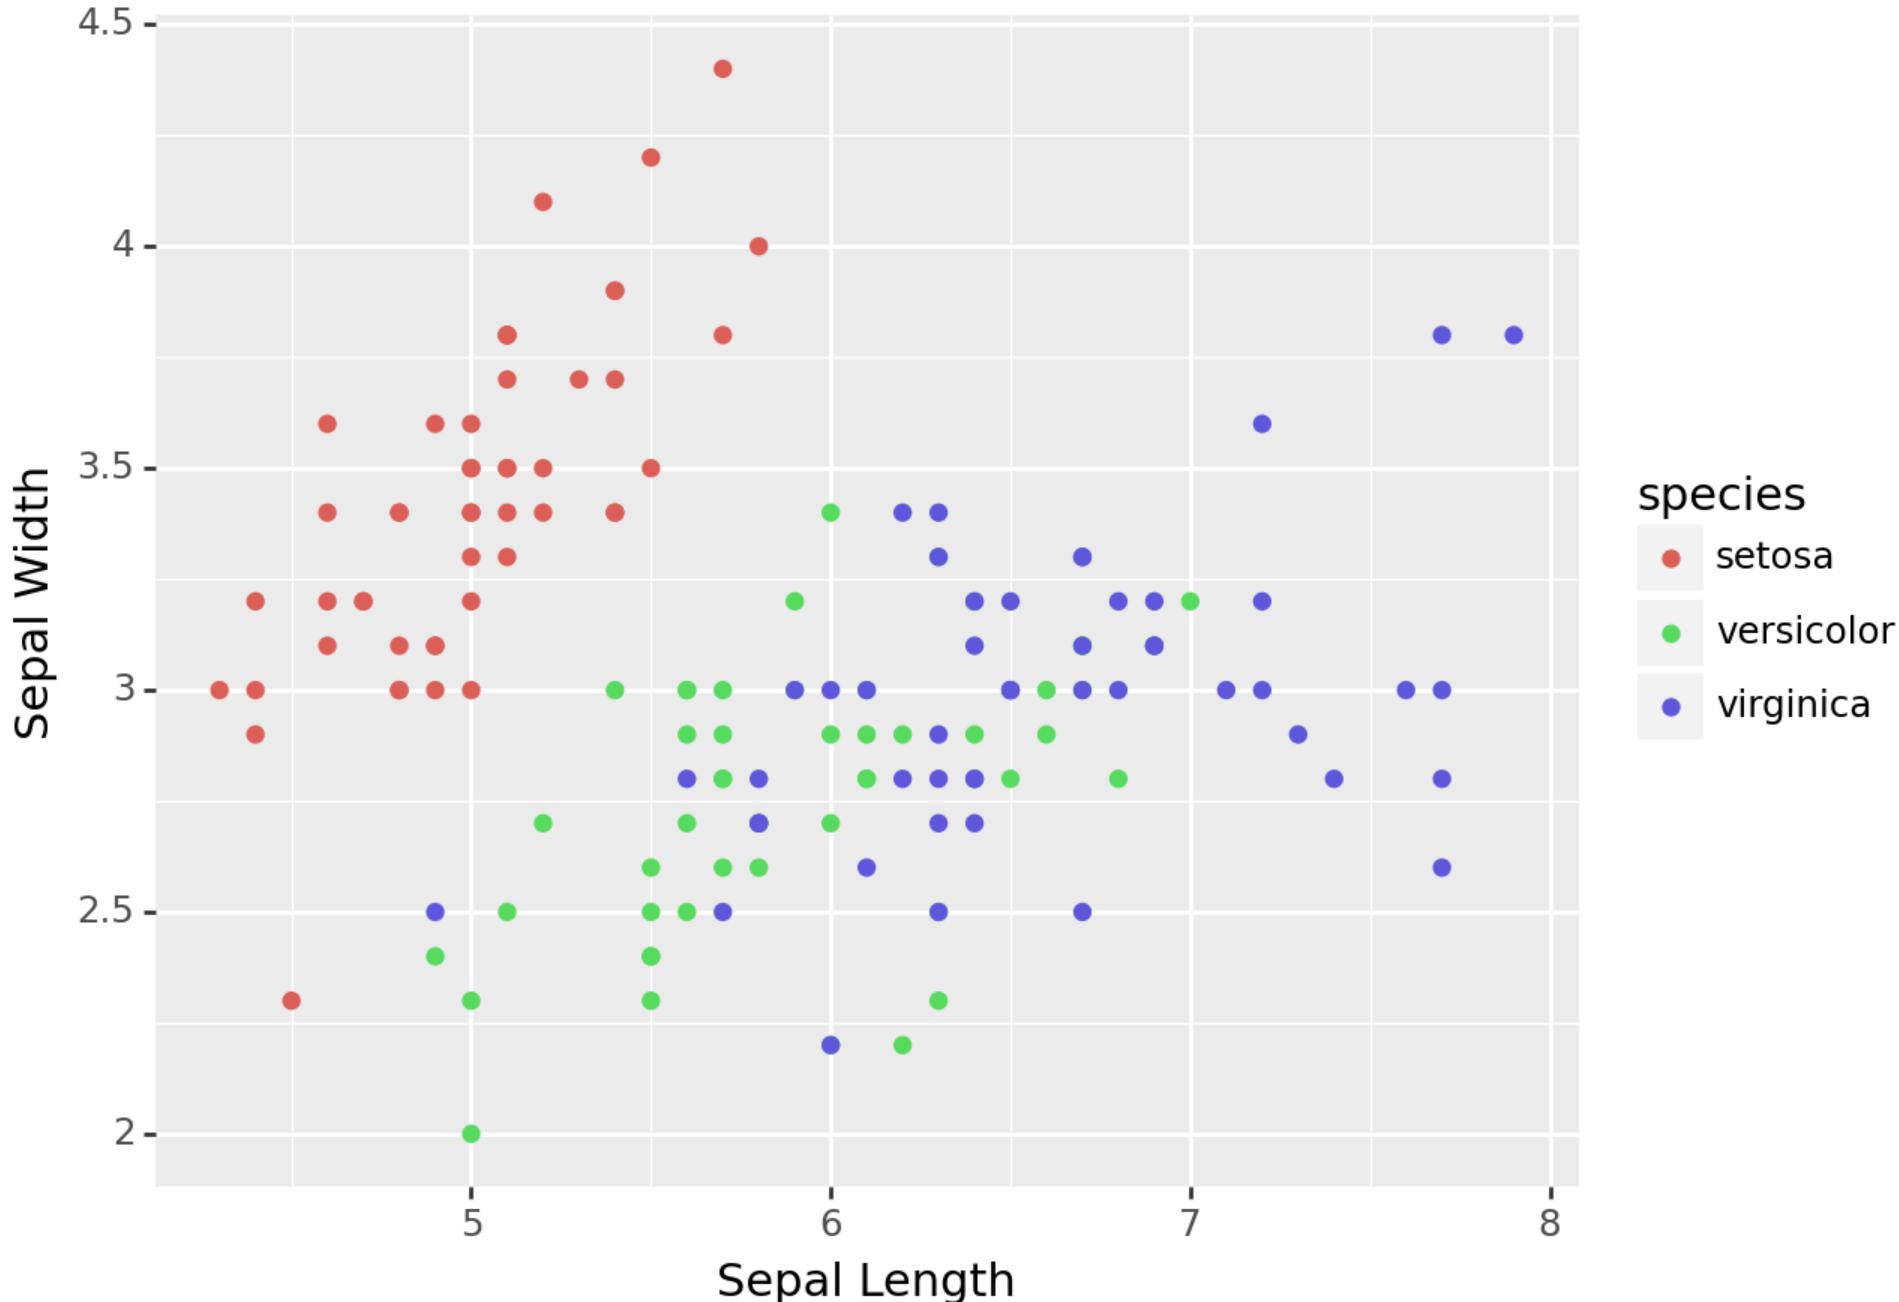
## Plotnine - diagramme de dispersion des sépales de l'iris

```
from plotnine import ggplot, aes, geom_point, labs

# Create a scatter plot of sepal size
scatter_plot = (
    ggplot(df_iris, aes(x='sepal_length', y='sepal_width', color='species')) +
    geom_point() +
    labs(title='Iris Dataset Scatter Plot', x='Sepal Length', y='Sepal Width')
)

# Display the plot
print(scatter_plot)
```

# Scatter Plot of Sepal Size



# Plotnine

## Avantages

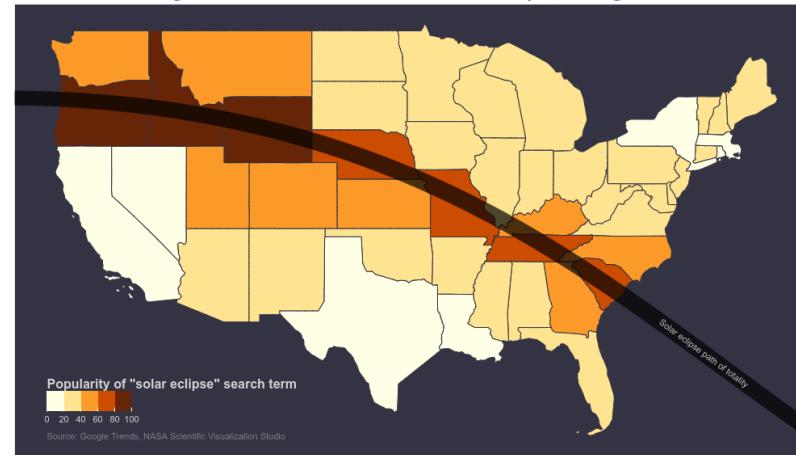
- Aussi puissant que ggplot2.
- Outil adapté aux utilisateurs de R utilisant Python.
- Grande variété de tracés possibles.

## Inconvénients

- La syntaxe n'est pas Python.
- Ne permet pas de tracer de grands ensembles de données.
- L'interactivité des tracés est limitée.

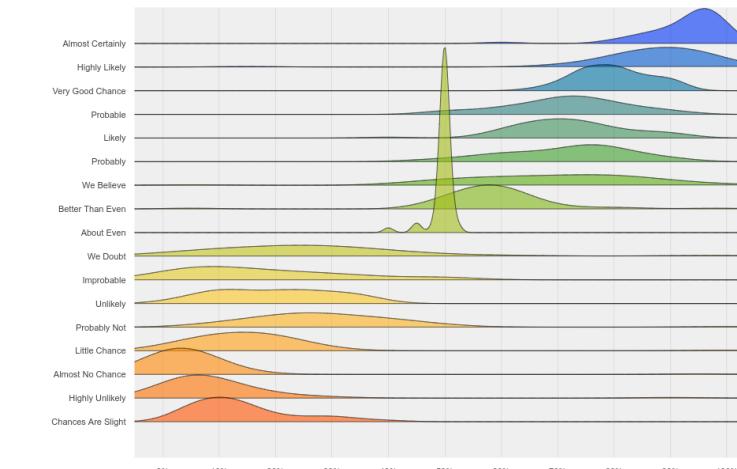
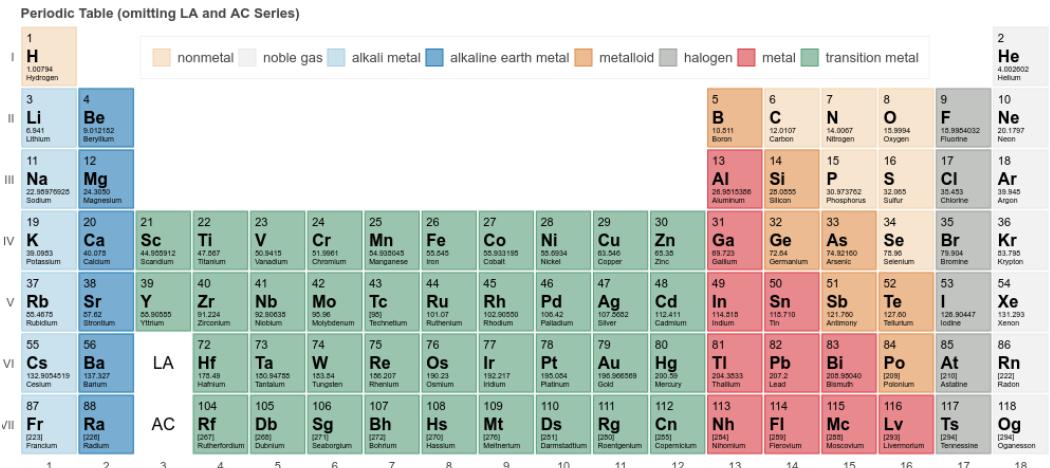


# Orienté Web



# Bokeh

- Utilisable dans Jupyter et IPython (sortie HTML par défaut).
- Capacité de créer des tableaux de bord.
- L'utilisation de WebGL est possible.



## Bokeh - diagramme de dispersion des sépales de l'iris

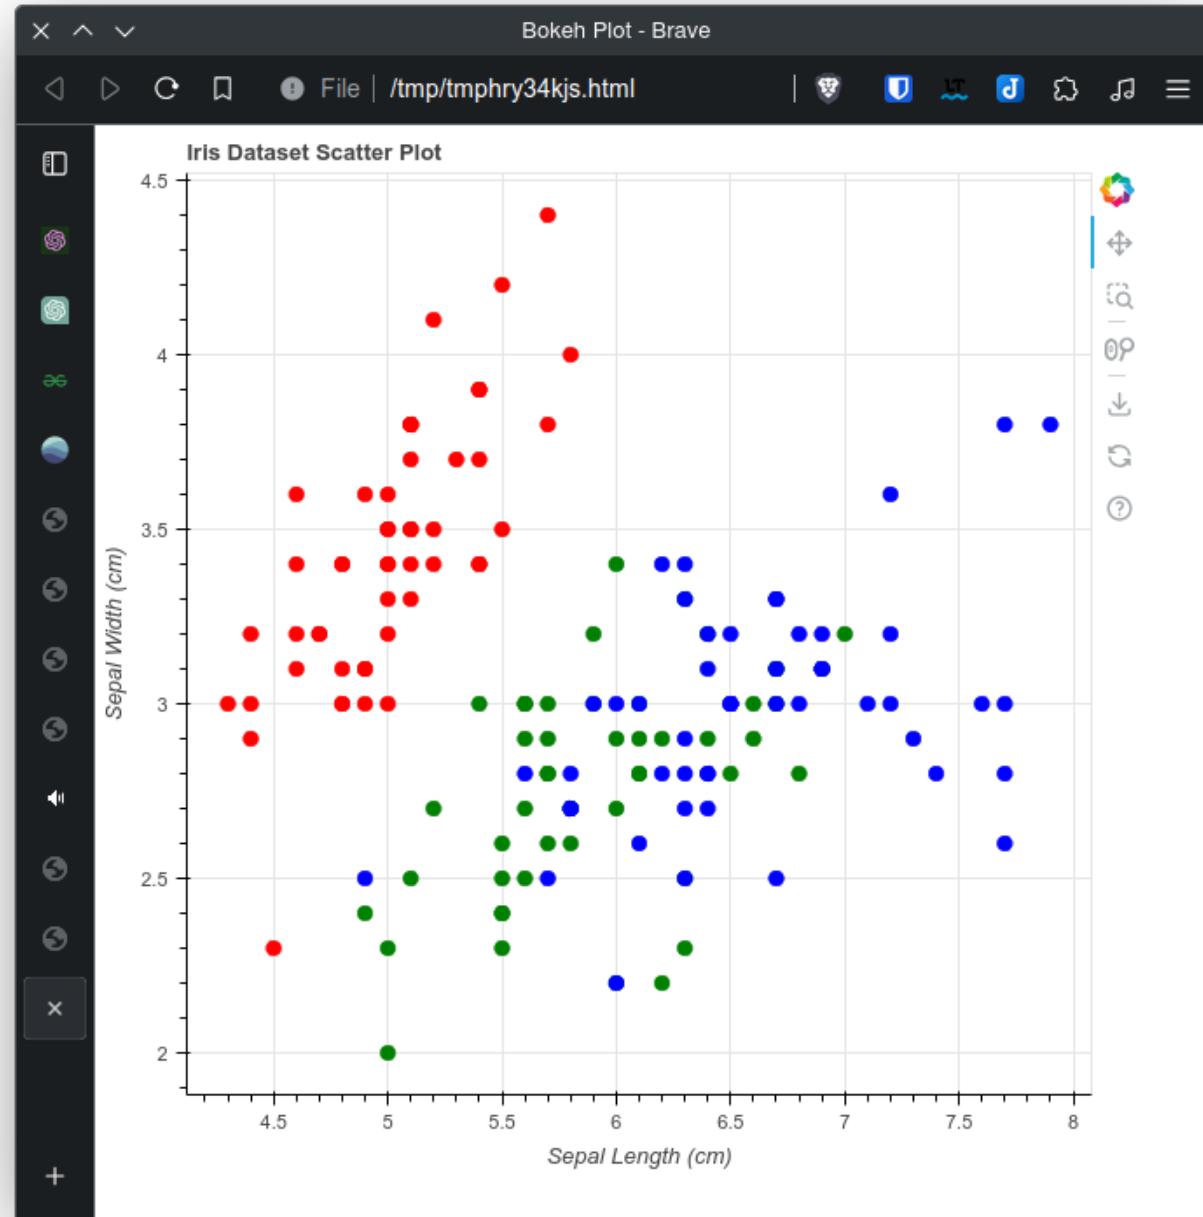
```
from bokeh.plotting import figure, show
from bokeh.transform import factor_cmap
from bokeh.models import ColumnDataSource

# Create a ColumnDataSource
source = ColumnDataSource(df_iris)

# Create a scatter plot with titles
p = figure(title='Iris Dataset Scatter Plot', x_axis_label='Sepal Length (cm)', y_axis_label='Sepal Width (cm)')

p.circle(x='sepal_length', y='sepal_width', source=source,
          size=8,
          color=factor_cmap(
              'species',
              palette=['red', 'green', 'blue'],
              factors=df_iris["species"].unique()
          )
)

# Show the plot
show(p)
```



# Bokeh

## Avantages

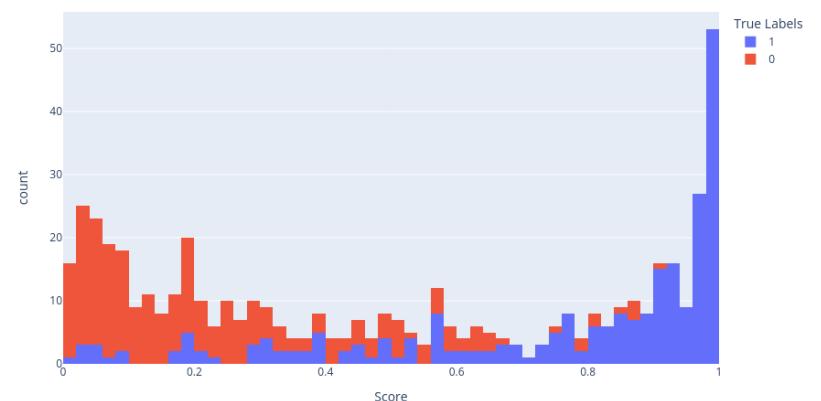
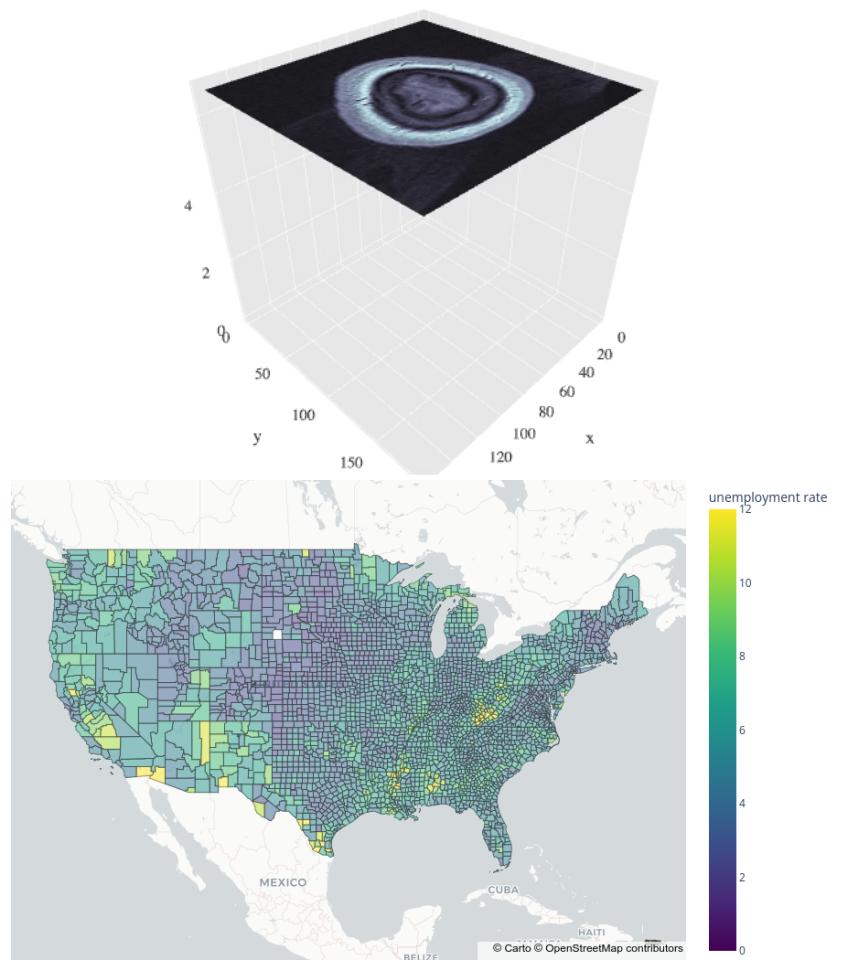
- API de bas niveau et de haut niveau.
- Peut facilement gérer un million de points.
- Interactivité (widgets et tableaux de bord).
- Capacité à réaliser de nombreux tracés différents.

## Inconvénients

- Plus difficile à apprendre que d'autres bibliothèques.
- Moins complet pour les tracés en 3D.
- Si les serveurs de Bokeh sont hors service, vos tracés peuvent ne pas s'afficher correctement (ou pas du tout).

# Plotly

- Conçu pour les visualisations interactives.
- L'utilisation de WebGL est possible.
- Utilisable avec Python, R et JavaScript.



## Plotly - diagramme de dispersion des sépales de l'iris

```
import plotly.express as px

fig = px.scatter(df_iris, x='sepal_length', y='sepal_width', color='species',
                  title='Iris Dataset Scatter Plot', labels={'sepal_length': 'Sepal Length', 'sepal_width': 'Sepal Width'})

# Show the plot
fig.show()
```



# Plotly

## Avantages

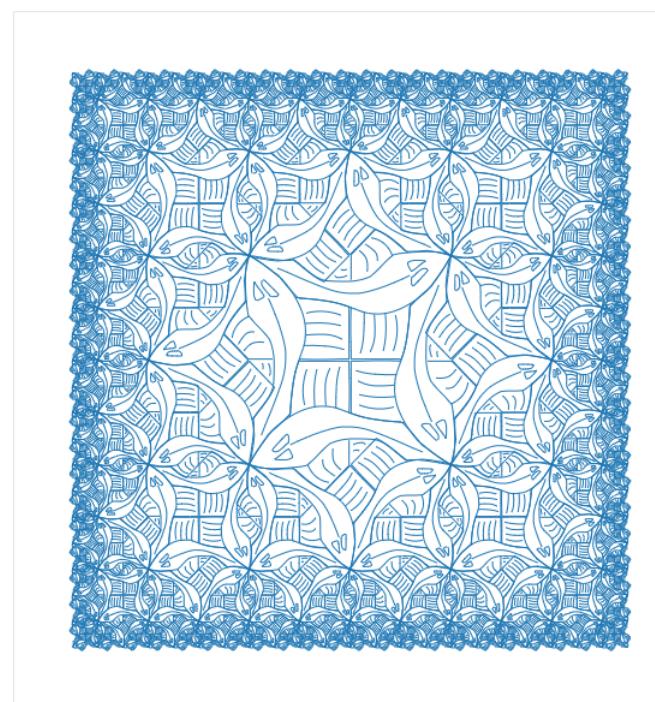
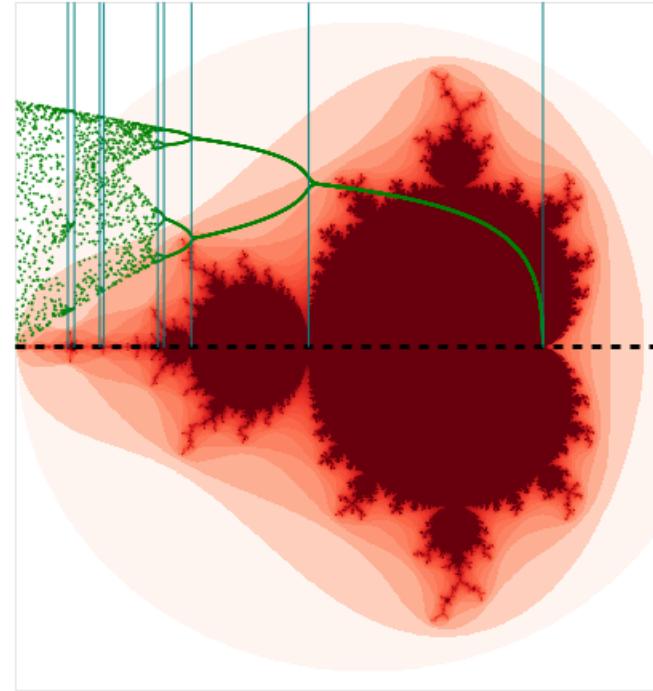
- La documentation est claire comme de l'eau de roche pour les tracés simples.
- Tableau de bord possible avec Dash (bien intégré).
- Redimensionnement automatique du graphique par défaut.

## Inconvénients

- Si les serveurs de Plotly sont en panne, vos tracés peuvent ne pas s'afficher correctement (ou pas du tout).
- Difficile d'utiliser des images comme tiques.

## Holoviews

Une bibliothèque de haut niveau  
pour Bokeh, Matplotlib et Plotly.



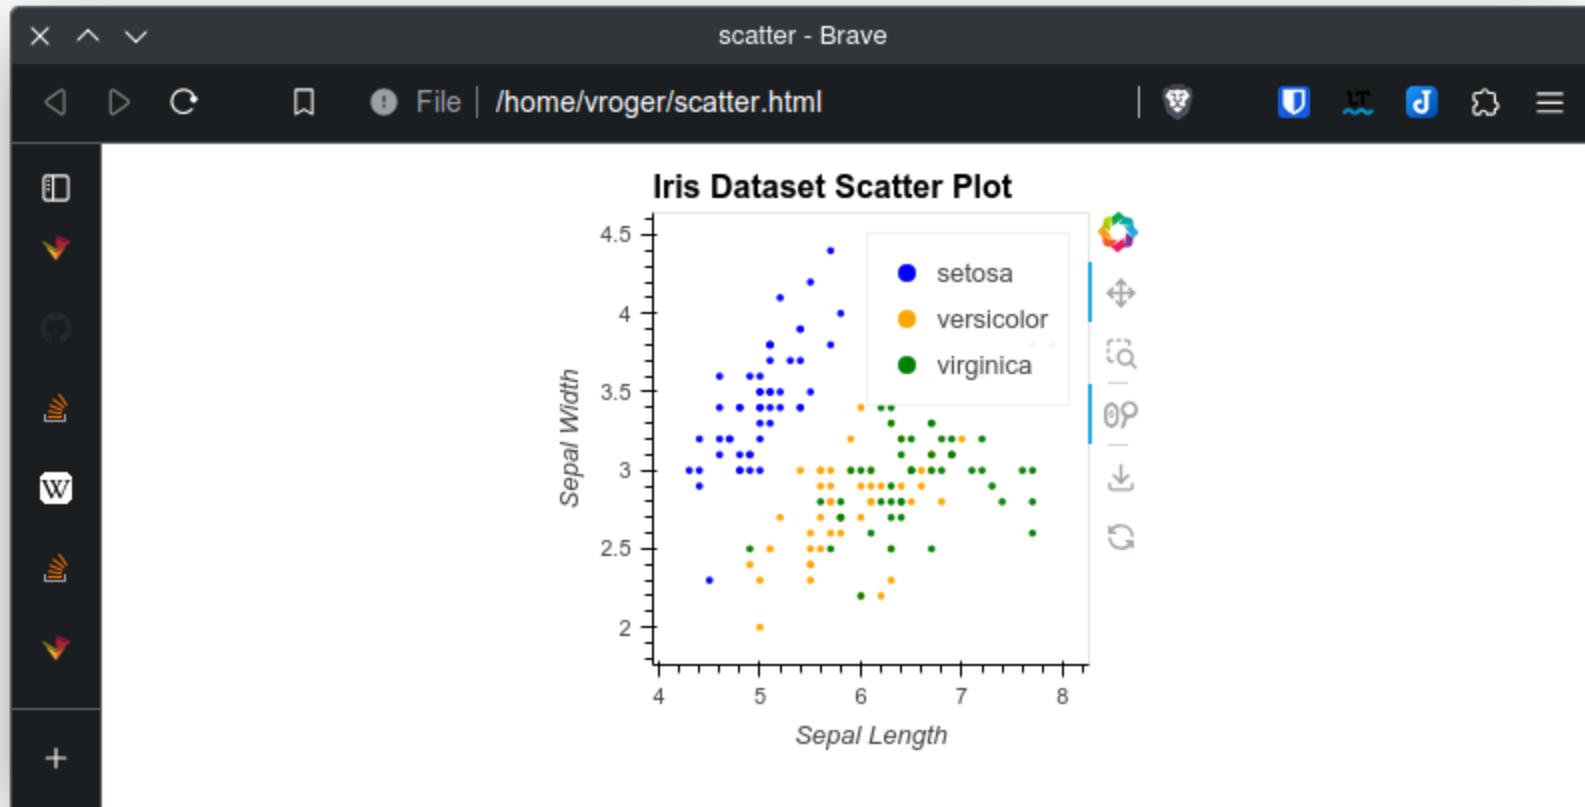
## Holoviews - diagramme de dispersion des sépales de l'iris

```
import holoviews as hv

scatter = hv.Scatter(
    data=df_iris, kdims=['sepal_length'], vdims=['sepal_width', 'species'],
).opts(color='species', cmap=['blue', 'orange', 'green'])

scatter = scatter.opts(
    title="Iris Dataset Scatter Plot",
    xlabel='Sepal Length',
    ylabel='Sepal Width',
)

hv.save(scatter, 'scatter.html', backend='bokeh')
```

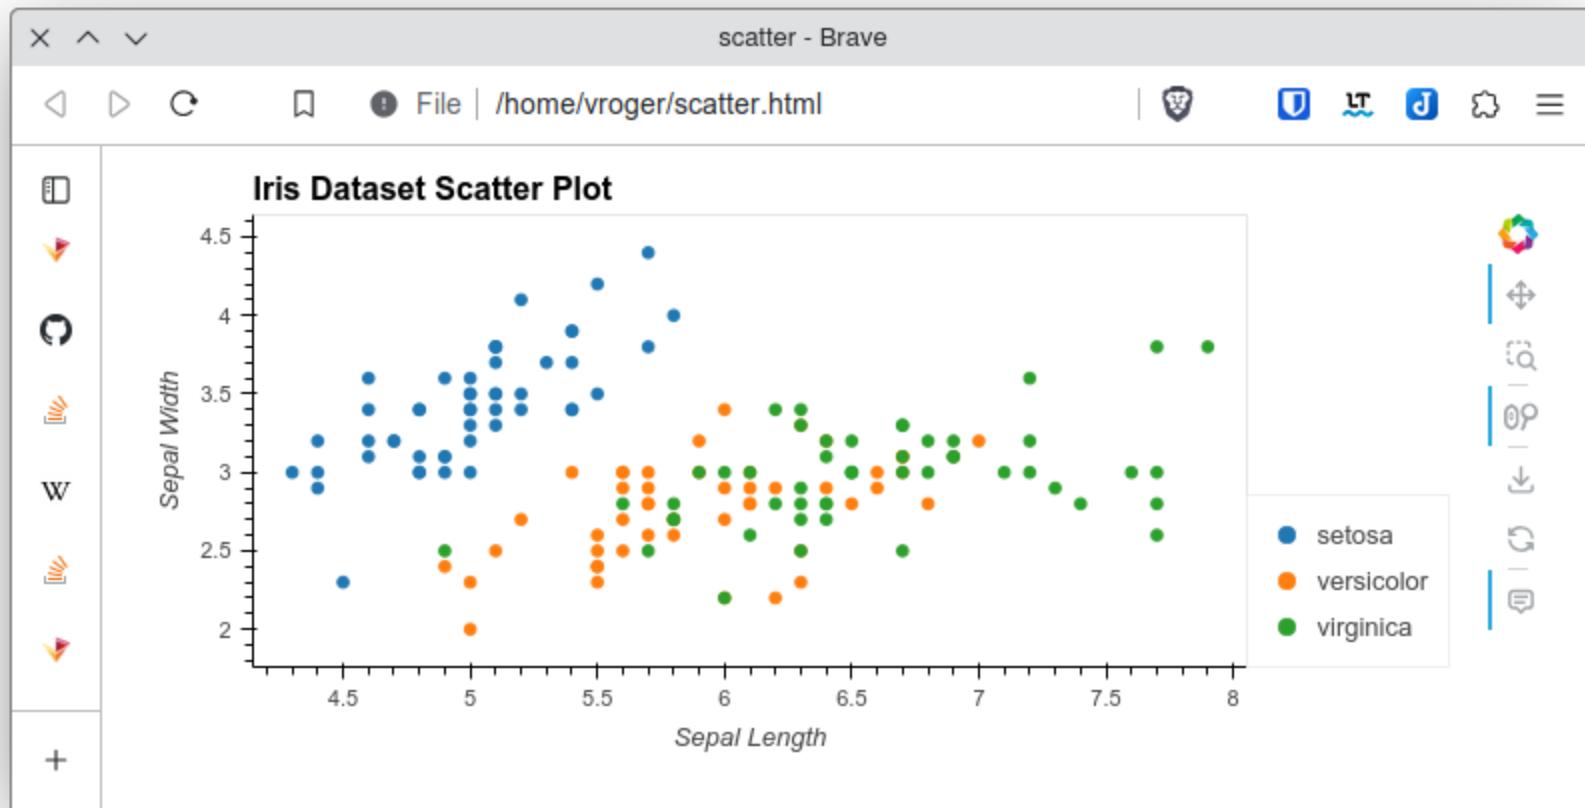


## Holoviews - diagramme de dispersion des sépales de l'iris avec l'API Pandas

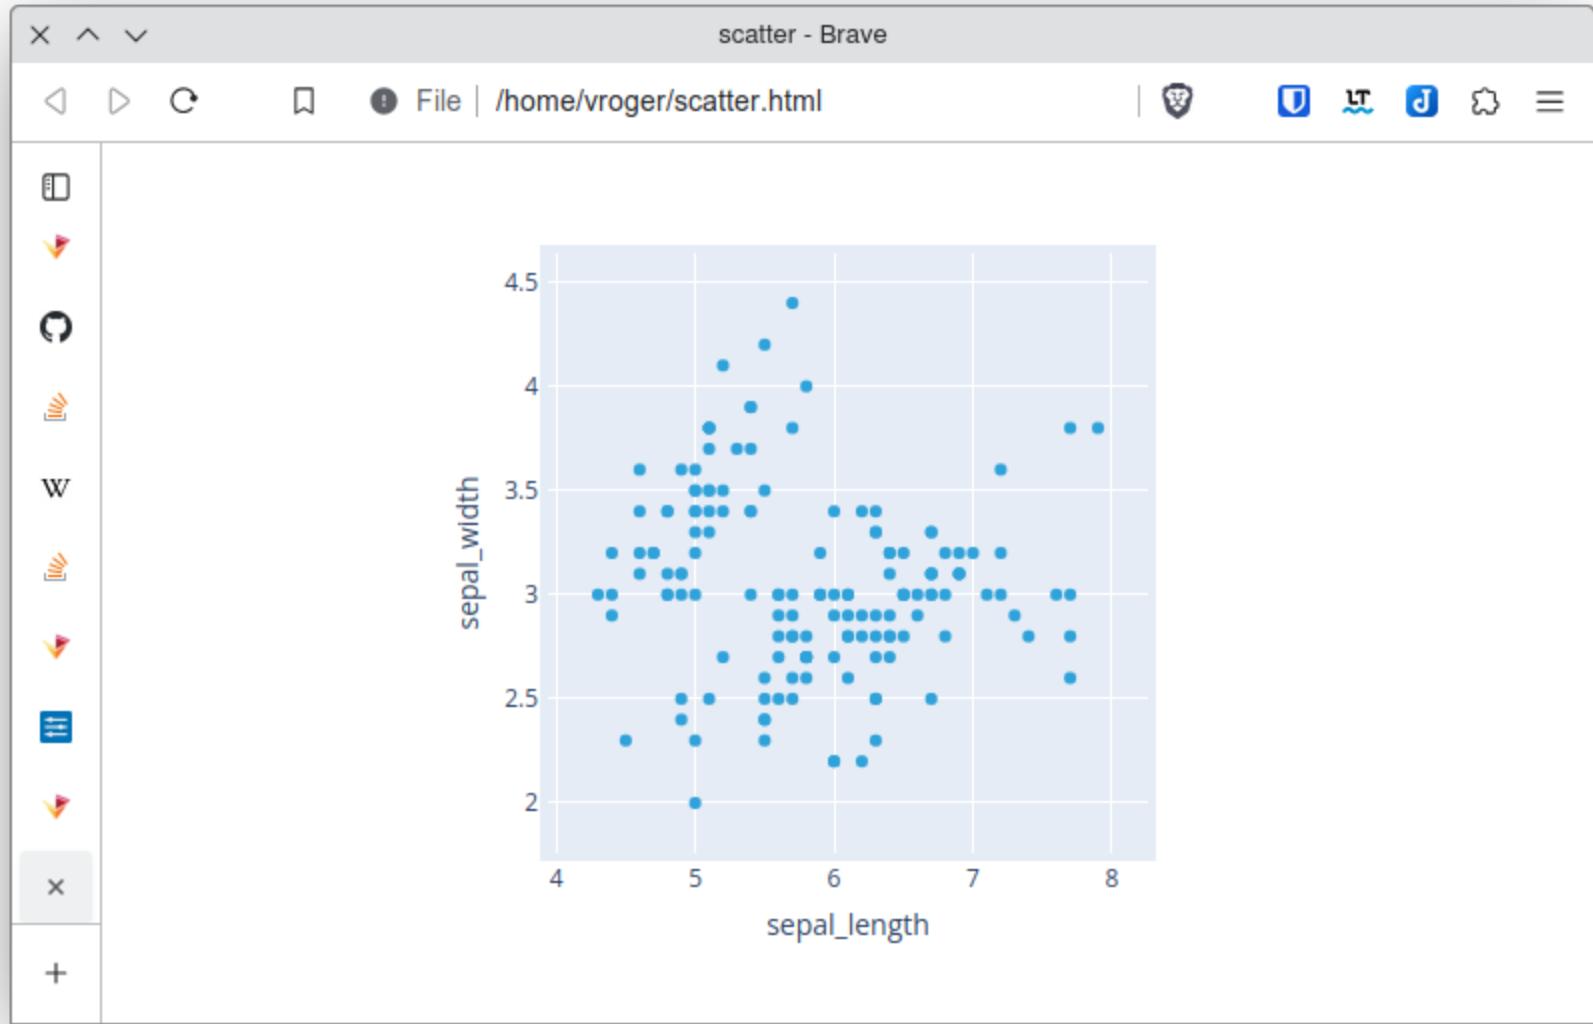
```
import hvplot
import hvplot.pandas
import holoviews as hv

scatter = df_iris.hvplot(kind='scatter', x='sepal_length', y='sepal_width', color='species')

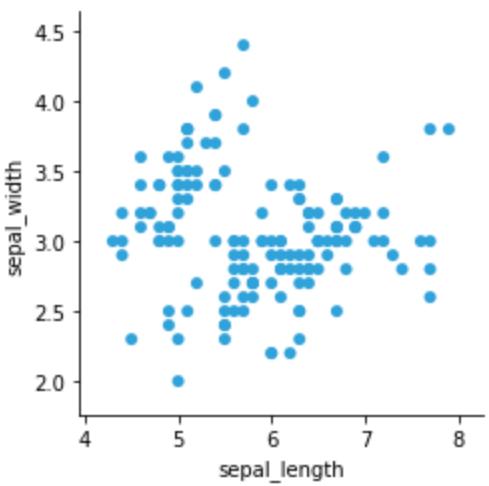
scatter = scatter.opts(
    title="Iris Dataset Scatter Plot",
    xlabel='Sepal Length',
    ylabel='Sepal Width',
)
hv.save(scatter, 'scatter.html', backend='bokeh')
```

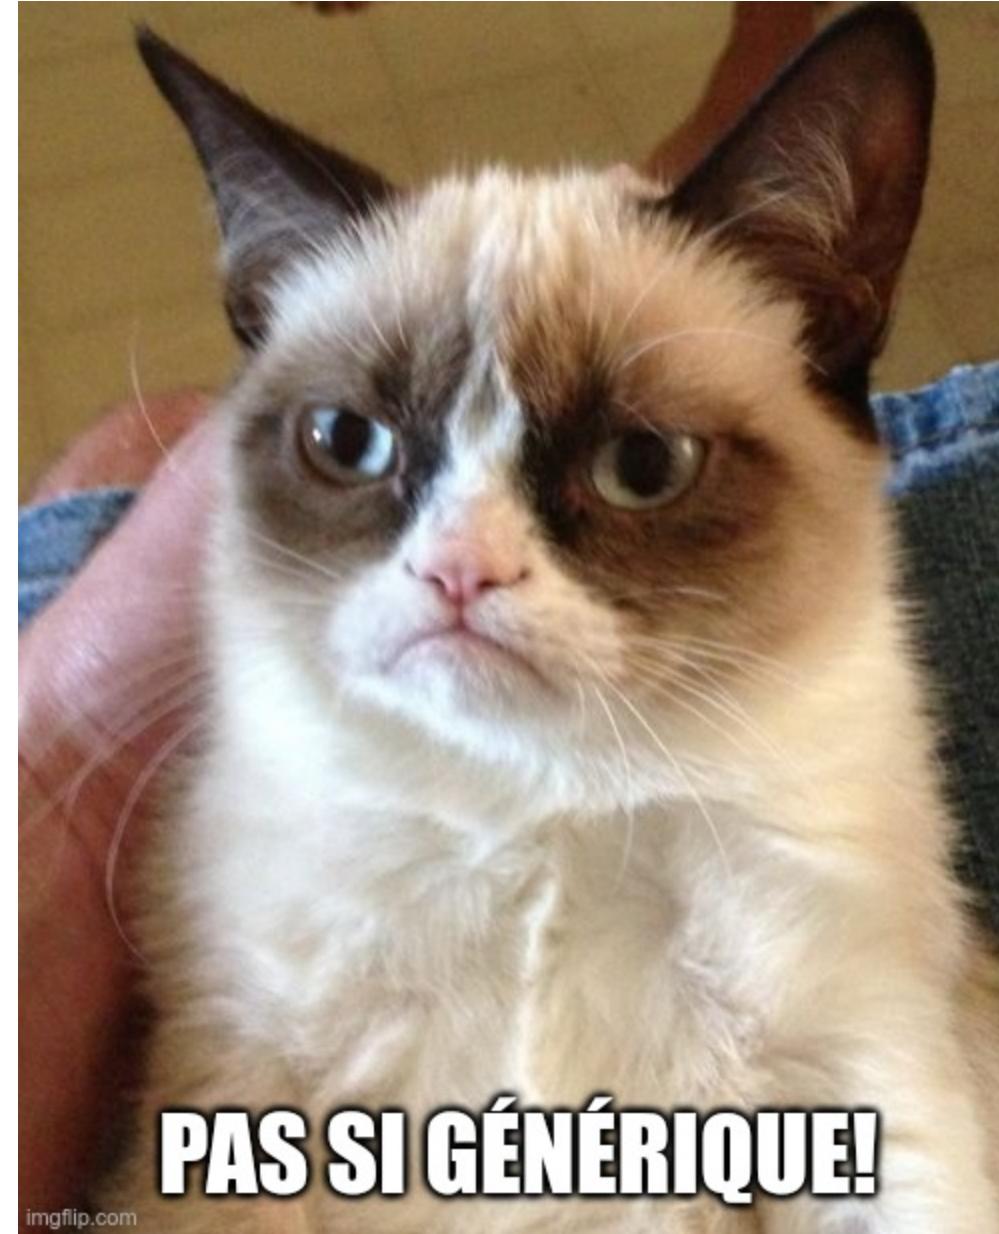


```
hv.save(scatter, 'scatter.html', backend='plotly')
```



```
hv.save(scatter, 'scatter.png', backend='matplotlib')
```





**PAS SI GÉNÉRIQUE!**

imgflip.com

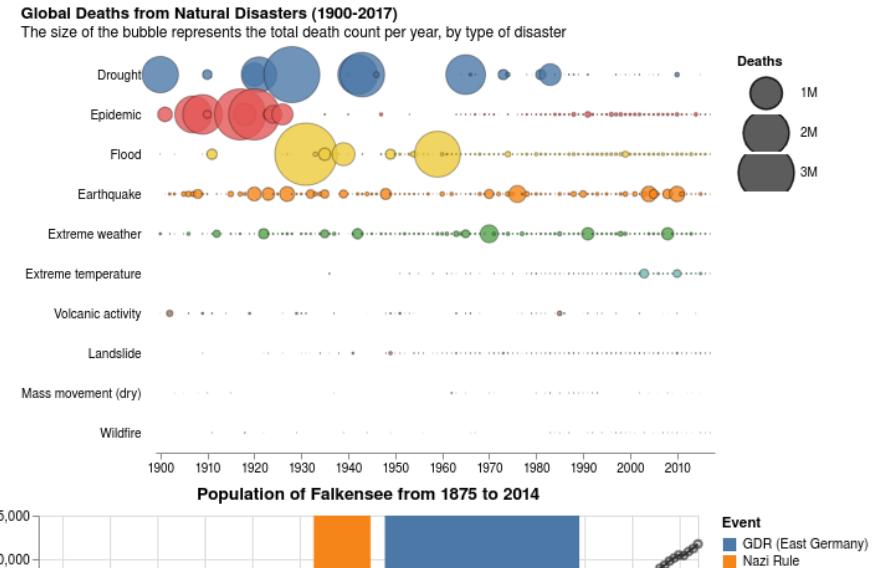
## Holoviews

### Avantages

- Fonctionne bien avec Bokeh.
- API de haut niveau.

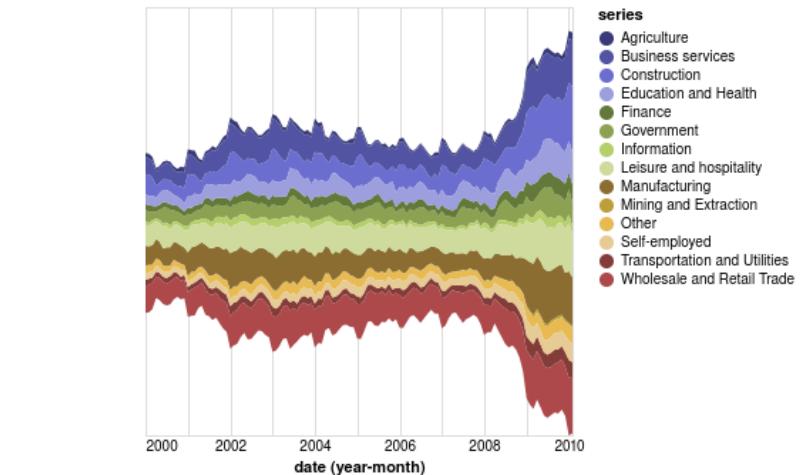
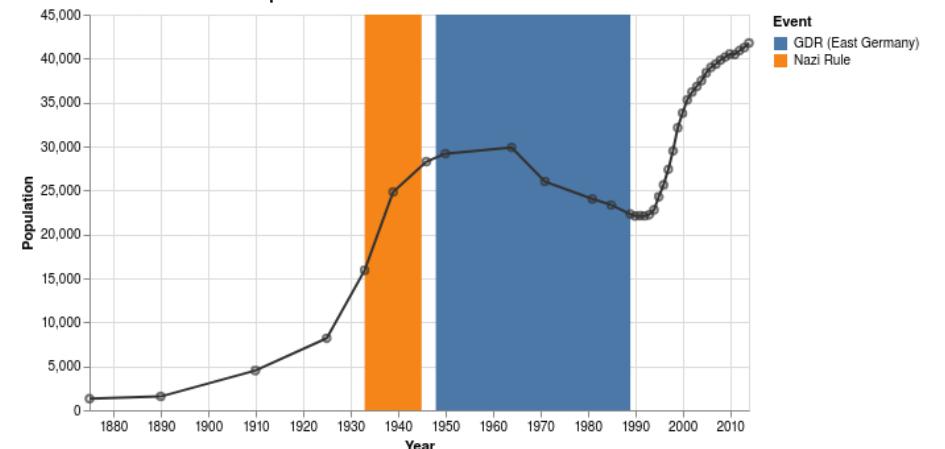
### Désavantages

- Pas générique (du moins pour l'instant).



# Altair

- Conçu pour les ordinateurs portables.
- Utilise le moteur Vega (qui produit du code JavaScript).

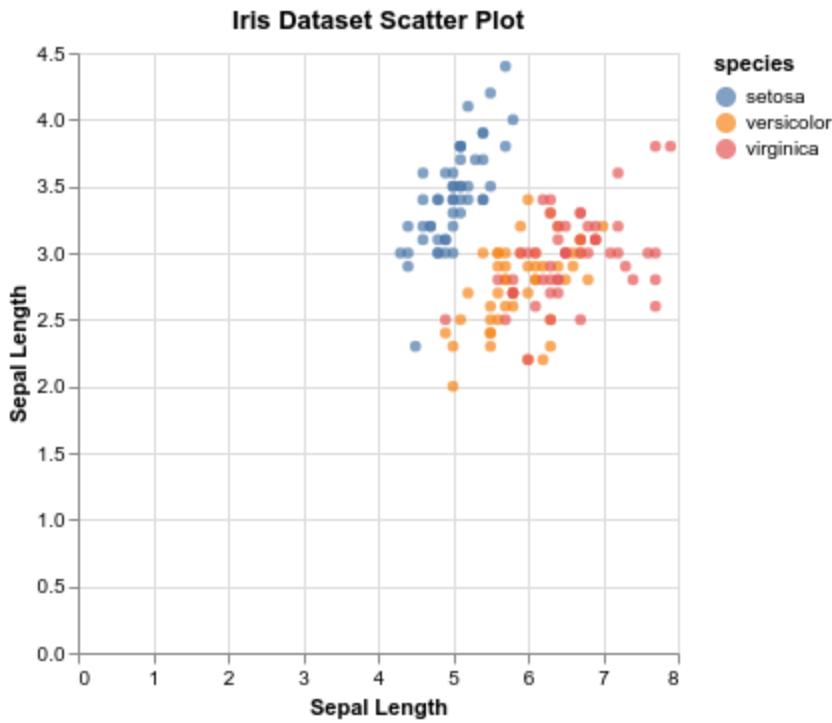


## Altair - diagramme de dispersion des sépales de l'iris

```
import altair as alt

# Create the scatter plot
scatter_plot = alt.Chart(df_iris).mark_circle().encode(
    x=alt.X('sepal_length', title='Sepal Length'),
    y=alt.Y('sepal_width', title='Sepal Width'),
    color='species'
).properties(
    title='Iris Dataset Scatter Plot'
)

# Show the plot
scatter_plot
```



# Altair

## Avantages

- Utilisation simple des dataframes.
- Performances plus agréables qu'un Plotly dans un notebook VS Code.

## Inconvénients

- Les valeurs par défaut ne sont pas très bonnes pour les graphiques statistiques.
- Pas de visualiseur pour les dernières versions (5.x).
- Personnalisation limitée des graphiques.

# Conclusion



# Mon choix

## Plotly

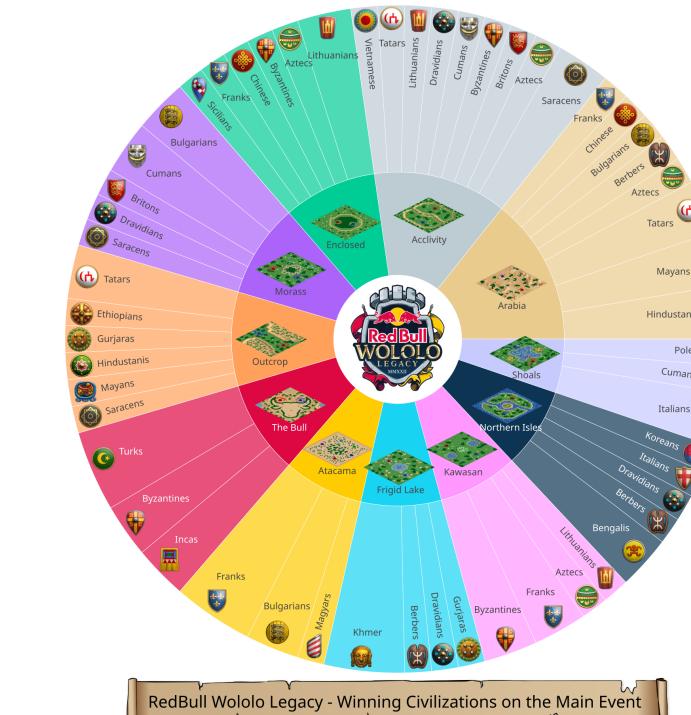
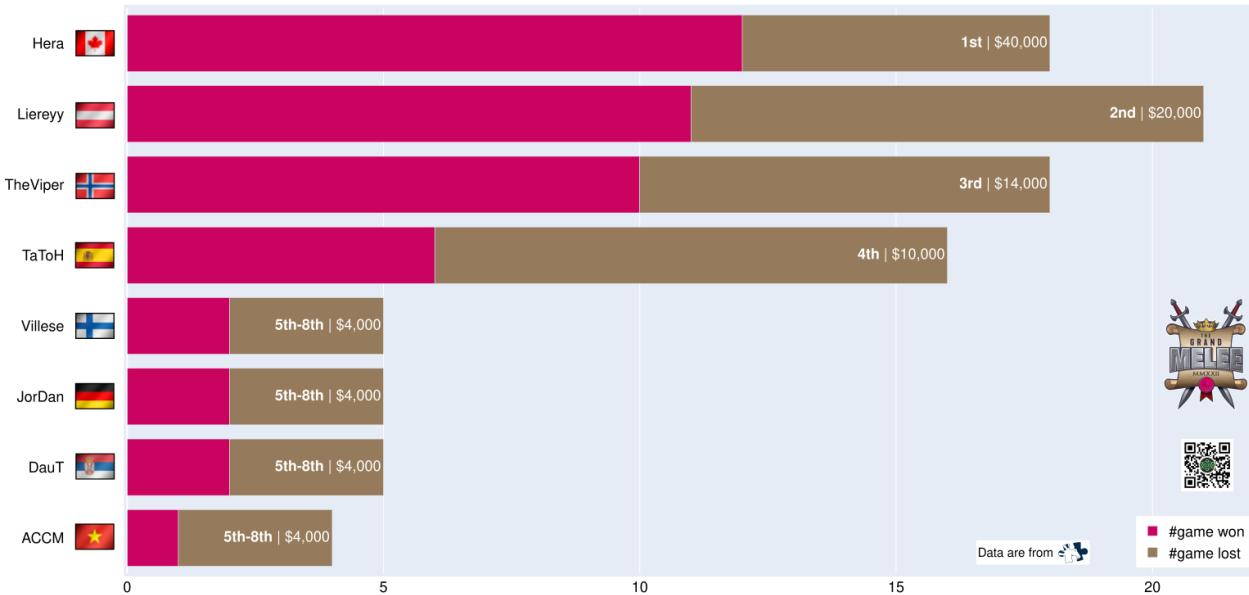
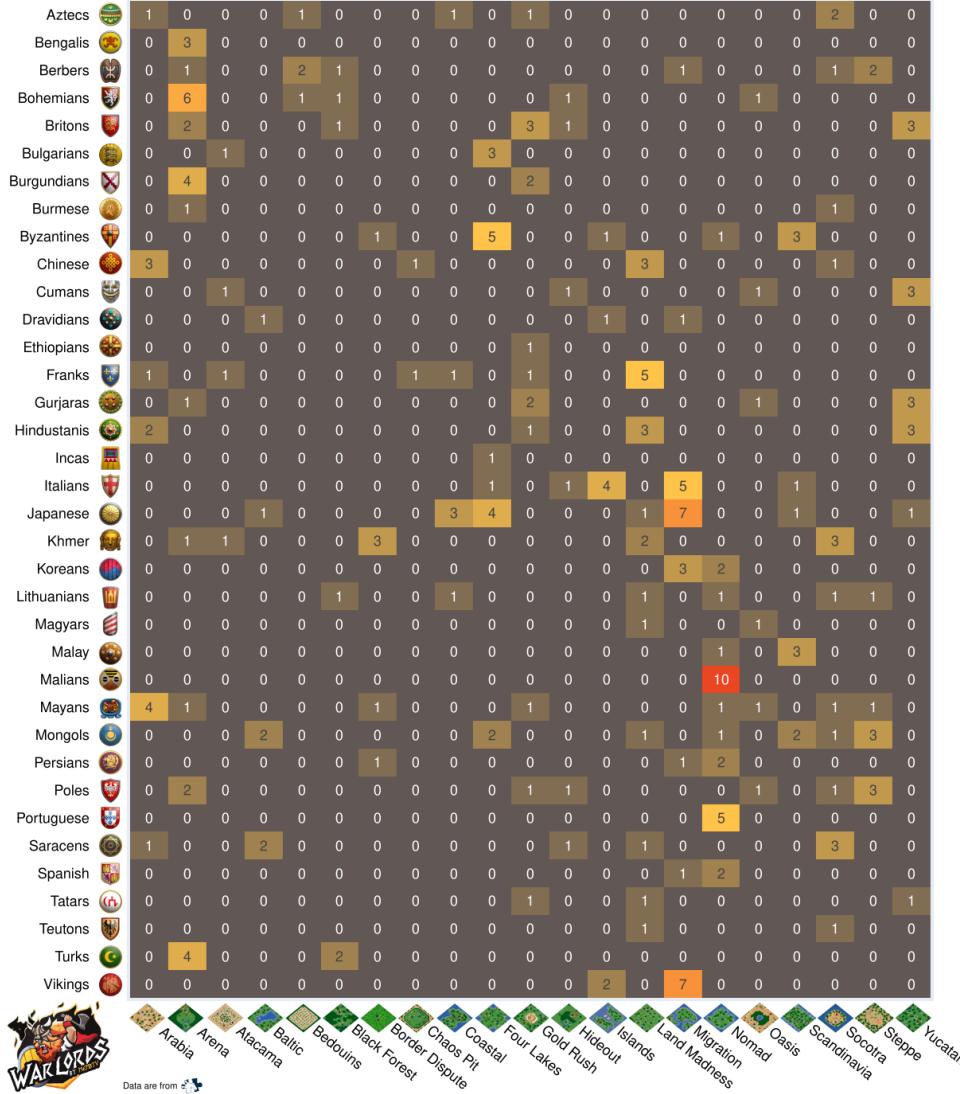
### Avantages

- Excellentes valeurs par défaut qui réduisent mes codes.
- Excellente documentation.
- Supporté par MLFlow.

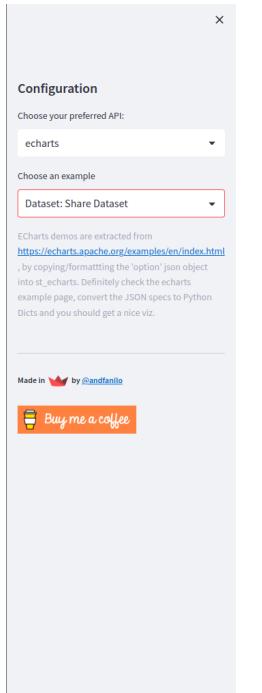
### Inconvénients

- Beaucoup de tracés dans les notebooks VSCode implique des ralentissements.
- Avoir des images en tant que ticks est difficile à mettre en œuvre (si vous connaissez un moyen simple, n'hésitez pas).

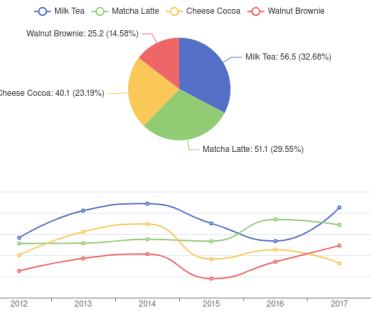
# Certains de mes travaux



# Bonus dashboard/webapp avec Streamlit



## Streamlit ECharts Demo



Source Code

Credit: <https://echarts.apache.org/examples/en/editor.html?c=dataset-link>

Made with Streamlit

Merci d'avoir écouté !