

**Vincent Roger**, (PhD)

## Scientifique des données et de l'apprentissage automatique

@ roger.vincent.11@gmail.com

+336 33 25 61 97

1 Rue Saint Dominique, 31000 Toulouse

vincent-roger.fr/fr

vroger11

vroger11

Vincent-Roger



## Compétences

**Cycle de vie d'un projet d'IA** : Audit, étude des besoins, collecte de données, ingénierie des caractéristiques des signaux, développement de modèles, déploiement et maintenance post-déploiement.

**Techniques d'apprentissage automatique** : Apprentissage supervisé, auto-supervisé et semi-supervisé ; réseaux neuronaux profonds (données massives et petits ensembles) ; apprentissage de séquences (RNN, GRU, transformers, HMM) ; modèles génératifs (Diffusion, GAN, DPGMM).

**Ingénierie des données & visualisation** : Analyse de données massives, traitement du signal (image et audio), visualisations interactives.

**MLOps** : Prototypage, développement d'API (FastAPI), microservices (Docker), CI/CD avec GitHub Actions, tests avec Pytest, suivi des modèles avec MLFlow, gestion de version avec DVC, gestionnaire de dépendances (Conda and Poetry).

**Langages de programmation & outils** : Python, Numpy, Scipy, PyTorch, Lightning, Scikit-learn, Pandas/Polars, Plotly, Streamlit, Diffusers, Transformers.

**Gestion de projet** : Organisé (philosophie Second Brain), leadership, collaboration en équipe, gestion des risques, respect des délais, conception de solutions, documentation technique (MkDocs).

**Langues** : Français (natif), Anglais (C1).

## Expériences professionnelles

**Ingénieur data et apprentissage automatique**, en cours, *Kiviak Instrument* Toulouse 2023–  
Maintenant  
Travail à distance avec responsabilité sur la sélection des données et des technologies utilisées. Conception et développement de modèles intégrés sous forme de microservices pour l'étiquetage automatique de samples de musique. Développement de prototypes de traitement du signal (algorithmes d'étiement du temps et de décalage de la hauteur). Création et intégration d'API de traitement du signal en tant que microservices. Participation à la réalisation du frontend associé (TypeScript). Développement d'algorithmes d'étiement temporel pour application temps réel. Actuellement en charge du développement de modèles de génération d'échantillons basés sur des modèles de diffusion.

**Thèse**, trois ans et trois mois, *Université de Toulouse* Toulouse 2018–2022  
Les personnes atteintes de cancers ORL présentent des difficultés de prononciation après des chirurgies ou des radiothérapies. Il est important pour le praticien de pouvoir disposer d'une mesure reflétant la sévérité de la parole. Je propose deux approches pour créer une mesure automatique, bien que ne disposant que de peu de données (environ 1h d'enregistrements audio pour 128 locuteurs). La première est fondée sur des méthodes de "few shot", tandis que la seconde est fondée sur la mesure entropique de caractéristiques de la parole (appries avec un modèle auto-supervisé sur un corpus annexe). Nos résultats sur cette dernière ont permis d'envisager une application médicale. Ainsi, j'ai obtenu une subvention pour encadrer un ingénieur afin de réaliser une application livrée au CHU de Toulouse.

**Ingénieur d'études**, deux ans, *Université de Toulon* Toulon 2016–2018  
Suite à mon précédent contrat, j'ai réalisé une représentation par modèle auto-supervisé profond des milieux acoustiques sous-marin pour aider à catégoriser les différents comportements des cétacés étant à portée des bouées. J'ai par la suite réalisé un modèle profond de classification de 1500 espèces d'oiseaux. Pour ces deux problèmes, je disposais de gros volumes de données.

**Ingénieur d'études**, dix mois, *LIS - TVT Innovation* Toulon 2015–2016  
Suite à la mise en place de bouées en mers équipées de microphone, nous disposons de grandes quantités de données. Mon travail consistait à modéliser l'environnement bioacoustique à l'aide de modèles génératifs. Grâce à cela, j'ai pu réaliser un rapport des activités des narvals en fonction de l'activité lunaire.

## Associations

**Travail bénévole**, en cours, *Toulouse Data Science*

📍 Toulouse

2023-  
Maintenant

Participation à l'organisation d'événements en présentiel.

**Travail bénévole**, 1 an et 6 mois, *Toulouse Dataviz*

📍 Toulouse

2022-2024

Participation à l'organisation d'événements en présentiel, à la création de posters, et à l'animation de formations pour les collégiens et le grand public.

## Enseignements

**Tutoriels pour générer des images**

2024

Une série de tutoriels que j'ai développée pour enseigner la bibliothèque Diffusers. Tout le code est disponible sur GitHub et les tutoriels sont publiés sur mon blog. Plus de détails sont disponibles ici : <https://github.com/vroger11/diffusers-tutorials>.

**Vacation**, Université de Toulouse

📍 Toulouse

2017-2018

- *Modèle et informatique* (cours - 14h): encadrement de projets Master pour l'apprentissage automatique sur la reconnaissance automatique de la parole.
- *Introduction à TensorFlow* (travaux pratiques - 6h): pour des étudiants de Master.
- *Probabilité et statistique* (travaux pratiques - 16h): utilisation basique des fonctions statistiques Scipy et Numpy pour des étudiants de Master.
- *Introduction à Python* (travaux pratiques - 116h): pour des étudiants de Licence en informatique, en économie et Master en biologie.
- *Introduction au réseau* (travaux pratiques - 10h): connaissances de base du modèle OSI et utilisation des commandes de base pour décrire l'état du réseau pour étudiants de Licence.

**Vacation**, Université de Toulon

📍 Toulon

2019-2021

- *Module Apprentissage* (travaux pratiques - 8h): enseignement et rédaction des sujets de travaux pratiques sur l'utilisation de modèles neuronaux avec TensorFlow pour étudiants de Master.
- *Module Algorithmique* (travaux dirigés - 8h): preuves algorithmiques et algorithmes de tris pour étudiants en Licence.
- *Module Recherche Opérationnelle* (travaux dirigés - 12h; travaux pratiques - 57h): enseignement et participation à la rédaction des sujets sur la théorie des graphes pour étudiants en Licence.

## Formations

**Doctorat**, Informatique, *Université Paul Sabatier*

📍 Toulouse

2022

J'ai amélioré ma communication à la radio et durant mes présentations.

**Master**, Intelligence Artificielle, *Université Paul Sabatier*

📍 Toulouse

2015

Modèles statistiques, traitement de signal, reconnaissance de formes, contrôle de robots et gestion de projets.

**Licence**, Informatique Fondamentale, *Université Paul Sabatier*

📍 Toulouse

2013

Outils de développement, programmation bas niveau, statistique, probabilités et calculatoire.

**DUT**, Informatique, *IUT Paul Sabatier*

📍 Toulouse

2011

Compétences techniques pour l'informatique et façons de designer des applications pour l'industrie.

## Centres d'intérêts

**Blogging**: Principalement des tutoriels, projets, visualisations et astuces sur l'environnement Linux.

**Sports**: Musculation (trois fois par semaine) et course (deux fois par semaine).

**Lectures**: Je lis sur la productivité, la santé, le sport et des Shōnens japonais.

